

---

## Ficha - Métodos de Otimização Sem Restrições

Métodos de descida acelerada: Momentum, NAG, Adagrad, RMSProp, Adam

---

1. Considere o problema (Rosenbrock)

$$\underset{w \in \mathbb{R}^2}{\text{minimizar}} F(w) = (a - w_1)^2 + b(w_2 - w_1^2)^2$$

com  $a = 1$  e  $b = 100$ . (Solução: minimizante global  $w^* = (a, a^2)$ )

Considere para ponto inicial  $w^{(0)} = (0, 0)^T$ , para critério de paragem considere a condição  $\|\nabla F(w)\| \leq 10^{-6}$ , e faça  $\eta = \text{constante}$ . Em cada iteração, grave para um ficheiro a informação:

$k$	$w^{(k)T}$	$\nabla F(w^{(k)})$	$\ \nabla F(w^{(k)})\ _2$	$F(w^{(k)})$
...	...	...	...	...

- (a) Resolva o problema usando o método NAG.
  - (b) Resolva o problema usando o método RMSProp.
  - (c) Resolva o problema usando o método Adam.
  - (d) Faça uma análise comparativa dos resultados obtidos.
2. Considere novamente o problema de *machine learning*. Dado o data set  $D = (x^n, y^n)_{n=1}^N$  pretende-se determinar os coeficientes de um polinómio de grau I

$$\begin{aligned}\phi(w; x) &= w_0 + w_1x + w_2x^2 + \dots + w_Ix^I \\ &= w^T p(x)\end{aligned}$$

onde  $p(x) = (1, x, x^2, \dots, x^I)^T$  que melhor ajustam o polinómio aos dados  $D$  no sentido da minimização da função MSE (*Mean Squared error*):

$$MSE(w; D) = \frac{1}{N} \sum_{n=1}^N (\phi(w; x^n) - y^n)^2.$$

**Nota:** O gradiente da função  $MSE(w; D)$  é dado por  $\nabla MSE(w; D) = \frac{2}{N} \sum_{n=1}^N (\phi(w; x^n) - y^n)p(x^n)$ .

- (a) Resolver o Problema apresentado com o data set data1.csv (N=100).  
Dividir o data set em duas partes: 80% para treino  $D_t$  e 20% para validação  $D_v$ . Esta seleção deverá ser aleatória. Resolva o problema com o método Adam (batch) e como aproximações iniciais aos parâmetros considere  $w^{(0)} = (0, \dots, 0)$ , e para critério de paragem considere

$$\|\nabla MSE(w)\| \leq 10^{-4} \text{ e } k \leq 10N_t.$$

Resolva o problema considerando polinómios de grau  $I = 2, \dots, 7$ . Para cada um dos polinómios calcule:  $w^*$ , o erro de treino (*in-sample error*)  $MSE(w^*; D_t)$ , e o erro de validação (*out-sample error*)  $MSE(w^*; D_v)$ . Fazer o gráfico dos erros e indicar qual o grau I que fornece a melhor aproximação.

- (b) Faça o exercício 2(a) mas implemente a versão Adam estocástico.
- (c) Faça o exercício 2(a) mas implemente a versão Adam estocástico mini-batch. Considere para mini-batch 5% dos dados do  $D_t$ . Esta seleção deverá ser aleatória em cada iteração.